

# Eine statistische Analyse des Netzwerks des internationalen Waffenhandels von 1950-2012

Christoph Jansen und Christian Schmid

Ludwig-Maximilians-Universität

28. Oktober 2014

## 1 Die Datengrundlage

- 1 Die Datengrundlage
- 2 Netzwerke als Graphen

- 1 Die Datengrundlage
- 2 Netzwerke als Graphen
- 3 Deskriptive Analyse

- 1 Die Datengrundlage
- 2 Netzwerke als Graphen
- 3 Deskriptive Analyse
- 4 Das Exponential Random Graph Model (ERGM)

- 1 Die Datengrundlage
- 2 Netzwerke als Graphen
- 3 Deskriptive Analyse
- 4 Das Exponential Random Graph Model (ERGM)
- 5 Inferentielle Analyse

# Die Datengrundlage

# Stockholm International Peace Research Institute (SIPRI)

- Die Daten stammen vom Stockholm International Peace Research Institute (SIPRI)



# Stockholm International Peace Research Institute (SIPRI)

- Die Daten stammen vom Stockholm International Peace Research Institute (SIPRI)
- Gründung 1966 als Stiftung der schwedischen Regierung

# Stockholm International Peace Research Institute (SIPRI)

- Die Daten stammen vom Stockholm International Peace Research Institute (SIPRI)
- Gründung 1966 als Stiftung der schwedischen Regierung
- Unabhängige internationale Forschungseinrichtung mit den Schwerpunkten Konfliktforschung und Rüstungskontrolle

# Stockholm International Peace Research Institute (SIPRI)

- Die Daten stammen vom Stockholm International Peace Research Institute (SIPRI)
- Gründung 1966 als Stiftung der schwedischen Regierung
- Unabhängige internationale Forschungseinrichtung mit den Schwerpunkten Konfliktforschung und Rüstungskontrolle
- Hauptsitz: Stockholm, weitere Niederlassungen in Washington D.C. und Peking

## Trend Indicator Value (TIV)

- Der *Trend Indicator Value (TIV)* ist eine (von SIPRI entwickelte) Kennzahl zur Messung der Intensität von Waffenhandel.

## Trend Indicator Value (TIV)

- Der *Trend Indicator Value (TIV)* ist eine (von SIPRI entwickelte) Kennzahl zur Messung der Intensität von Waffenhandel.
- Beispielsweise erhält

## Trend Indicator Value (TIV)

- Der *Trend Indicator Value (TIV)* ist eine (von SIPRI entwickelte) Kennzahl zur Messung der Intensität von Waffenhandel.
- Beispielsweise erhält
  - ein Leopard-2A4 Panzer einen TIV von 4 Millionen
  - ein Eurofighter einen TIV von 55 Millionen
  - ein U-Boot (Typ 209PN) einen TIV von 275 Millionen

## Trend Indicator Value (TIV)

- Der *Trend Indicator Value (TIV)* ist eine (von SIPRI entwickelte) Kennzahl zur Messung der Intensität von Waffenhandel.
- Beispielsweise erhält
  - ein Leopard-2A4 Panzer einen TIV von 4 Millionen
  - ein Eurofighter einen TIV von 55 Millionen
  - ein U-Boot (Typ 209PN) einen TIV von 275 Millionen
- Warum wird nicht direkt der Verkaufspreis als Kennzahl verwendet?

# Trend Indicator Value (TIV)

- Der *Trend Indicator Value (TIV)* ist eine (von SIPRI entwickelte) Kennzahl zur Messung der Intensität von Waffenhandel.
- Beispielsweise erhält
  - ein Leopard-2A4 Panzer einen TIV von 4 Millionen
  - ein Eurofighter einen TIV von 55 Millionen
  - ein U-Boot (Typ 209PN) einen TIV von 275 Millionen
- Warum wird nicht direkt der Verkaufspreis als Kennzahl verwendet?
  - ① Oftmals unbekannt: Für Waffen(systeme) existiert kein offizieller Marktpreis
  - ② Häufig nicht repräsentativ: Auch politische Erwägungen beeinflussen Preise



# Die Datengrundlage I

# Die Datengrundlage I

- Für jedes Jahr im Zeitraum 1950-2012 wurden für jede Nation der
  - Gesamt-Export-TIV
  - Gesamt-Import-TIVmit allen anderen (im entsprechenden Jahr existierenden) Nationen erfasst.

# Die Datengrundlage I

- Für jedes Jahr im Zeitraum 1950-2012 wurden für jede Nation der
  - Gesamt-Export-TIV
  - Gesamt-Import-TIV
 mit allen anderen (im entsprechenden Jahr existierenden) Nationen erfasst.
- Beispielsweise liegen die Rohdaten für den Export der BRD in der folgenden Form vor:

	1950	...	2012
Afghanistan	$\text{TIV}(\text{BRD} \rightarrow \text{AFG}, 1950)$	...	$\text{TIV}(\text{BRD} \rightarrow \text{AFG}, 2012)$
⋮	⋮	⋮	⋮
Zimbabwe	$\text{TIV}(\text{BRD} \rightarrow \text{ZIM}, 1950)$	...	$\text{TIV}(\text{BRD} \rightarrow \text{ZIM}, 2012)$

# Die Datengrundlage I

- Für jedes Jahr im Zeitraum 1950-2012 wurden für jede Nation der
  - Gesamt-Export-TIV
  - Gesamt-Import-TIV
 mit allen anderen (im entsprechenden Jahr existierenden) Nationen erfasst.
- Beispielsweise liegen die Rohdaten für den Export der BRD in der folgenden Form vor:

	1950	...	2012
Afghanistan	$\text{TIV}(\text{BRD} \rightarrow \text{AFG}, 1950)$	...	$\text{TIV}(\text{BRD} \rightarrow \text{AFG}, 2012)$
⋮	⋮	⋮	⋮
Zimbabwe	$\text{TIV}(\text{BRD} \rightarrow \text{ZIM}, 1950)$	...	$\text{TIV}(\text{BRD} \rightarrow \text{ZIM}, 2012)$

- Import-Rohdaten liegen in analoger Form vor, ersetze  $\rightarrow$  durch  $\leftarrow$ .

# Die Datengrundlage II

# Die Datengrundlage II

- Daten in dieser Form (insbesondere für die Netzwerkanalyse) kaum verwertbar!

# Die Datengrundlage II

- Daten in dieser Form (insbesondere für die Netzwerkanalyse) kaum verwertbar!
- Transformation wird vorgenommen: Man erhält für jedes Jahr  $x \in \{1950, \dots, 2012\}$  die Matrizen

$\text{EXP}(x) :=$

	Afghanistan	...	Zimbabwe
Afghanistan	0	...	$\text{TIV}(\text{AFG} \rightarrow \text{ZIM}, x)$
$\vdots$	$\vdots$	$\vdots$	$\vdots$
Zimbabwe	$\text{TIV}(\text{ZIM} \rightarrow \text{AFG}, x)$	...	0

$\text{IMP}(x) :=$

	Afghanistan	...	Zimbabwe
Afghanistan	0	...	$\text{TIV}(\text{AFG} \leftarrow \text{ZIM}, x)$
$\vdots$	$\vdots$	$\vdots$	$\vdots$
Zimbabwe	$\text{TIV}(\text{ZIM} \leftarrow \text{AFG}, x)$	...	0

# Die Datengrundlage III

- Gute Überprüfungsmöglichkeit der Daten durch Spiegelung:



# Die Datengrundlage III

- Gute Überprüfungsmöglichkeit der Daten durch Spiegelung:
  - Gilt  $\text{IMP}(x) = t(\text{EXP}(x))$  für alle  $x \in \{1950, \dots, 2012\}$ ?

# Die Datengrundlage III

- Gute Überprüfungsmöglichkeit der Daten durch Spiegelung:
  - Gilt  $\text{IMP}(x) = t(\text{EXP}(x))$  für alle  $x \in \{1950, \dots, 2012\}$ ?
  - Ergebnis: Für einige (wenige) Jahre sind (kleine) Fehler in den Daten. Diese sind aber vernachlässigbar, da es sich offenbar um Tippfehler handelt.

# Die Datengrundlage III

- Gute Überprüfungsmöglichkeit der Daten durch Spiegelung:
  - Gilt  $\text{IMP}(x) = t(\text{EXP}(x))$  für alle  $x \in \{1950, \dots, 2012\}$ ?
  - Ergebnis: Für einige (wenige) Jahre sind (kleine) Fehler in den Daten. Diese sind aber vernachlässigbar, da es sich offenbar um Tippfehler handelt.
- Da  $\text{IMP}(x)$  und  $\text{EXP}(x)$  theoretisch die selbe Information enthalten, wird von jetzt an nur noch mit  $\text{EXP}(x)$  gearbeitet.

# Die Datengrundlage III

- Gute Überprüfungsmöglichkeit der Daten durch Spiegelung:
  - Gilt  $\text{IMP}(x) = t(\text{EXP}(x))$  für alle  $x \in \{1950, \dots, 2012\}$ ?
  - Ergebnis: Für einige (wenige) Jahre sind (kleine) Fehler in den Daten. Diese sind aber vernachlässigbar, da es sich offenbar um Tippfehler handelt.
- Da  $\text{IMP}(x)$  und  $\text{EXP}(x)$  theoretisch die selbe Information enthalten, wird von jetzt an nur noch mit  $\text{EXP}(x)$  gearbeitet.
- Für jedes Jahr  $x$  lässt sich  $\text{EXP}(x)$  als ein gerichteter Graph auffassen.

# Die Datengrundlage III

- Gute Überprüfungsmöglichkeit der Daten durch Spiegelung:
  - Gilt  $\text{IMP}(x) = t(\text{EXP}(x))$  für alle  $x \in \{1950, \dots, 2012\}$ ?
  - Ergebnis: Für einige (wenige) Jahre sind (kleine) Fehler in den Daten. Diese sind aber vernachlässigbar, da es sich offenbar um Tippfehler handelt.
- Da  $\text{IMP}(x)$  und  $\text{EXP}(x)$  theoretisch die selbe Information enthalten, wird von jetzt an nur noch mit  $\text{EXP}(x)$  gearbeitet.
- Für jedes Jahr  $x$  lässt sich  $\text{EXP}(x)$  als ein gerichteter Graph auffassen.

⇒ Mathematische Behandlung mit Hilfe der Graphentheorie

## Die Datengrundlage IV

Supplier	Czech Rep.	Soviet Union	USA
Recipient	Eq. Guinea	Algeria	Canada
Designation	BMP-76		C-X
Weapon Type	Armoured vehicles	Ships	Aircraft
Number delivered	20	2	2
Number estimate	Yes	No	No
Order year	2005	1975	2007
Order year estimate	Yes	No	No
Delivery year	2007	1976	2008
Delivery year estimate	Yes	No	No
Status	Used	Used	New
TIV full unit	0.9	42.5	140
TIV deal unit value	0.36	17	140
TIV delivery value	7.2	34	280

# Netzwerke als Graphen

# Graphen

## Definition 1

Sei  $V$  eine endliche Menge und  $E \subset V \times V$ . Dann heit

$$G := (V, E)$$

*endlicher gerichteter Graph* auf  $n := |V|$  Ecken. Die Elemente von

- $V$  werden als *Ecken* (oder *Knoten*) bezeichnet
- $E$  werden als *Kanten* bezeichnet



# Graphen

## Definition 1

Sei  $V$  eine endliche Menge und  $E \subset V \times V$ . Dann heißt

$$G := (V, E)$$

*endlicher gerichteter Graph* auf  $n := |V|$  Ecken. Die Elemente von

- $V$  werden als *Ecken* (oder *Knoten*) bezeichnet
- $E$  werden als *Kanten* bezeichnet
- Für  $v_1, v_2 \in V$  bedeutet  $(v_1, v_2) \in E$  gerade, dass eine Kante von Ecke  $v_1$  zu Ecke  $v_2$  führt.

# Graphen

## Definition 1

Sei  $V$  eine endliche Menge und  $E \subset V \times V$ . Dann heißt

$$G := (V, E)$$

*endlicher gerichteter Graph* auf  $n := |V|$  Ecken. Die Elemente von

- $V$  werden als *Ecken* (oder *Knoten*) bezeichnet
- $E$  werden als *Kanten* bezeichnet
- Für  $v_1, v_2 \in V$  bedeutet  $(v_1, v_2) \in E$  gerade, dass eine Kante von Ecke  $v_1$  zu Ecke  $v_2$  führt.
- *Gerichtet* bedeutet, dass die Richtung der Kante eine Rolle spielt, d.h. es gilt **nicht**

$$(v_1, v_2) \in E \Leftrightarrow (v_2, v_1) \in E$$

# Adjazenzmatrix

## Definition 2

Sei  $G = (V, E)$  ein gerichteter Graph auf  $n$  Ecken und sei  $V := \{v_1, \dots, v_n\}$  eine Aufzählung der Ecken. Dann heißt  $A \in \mathbb{R}^{n \times n}$  mit

$$a_{ij} = \begin{cases} 1 & , \text{ falls } (v_i, v_j) \in E \\ 0 & , \text{ sonst} \end{cases}$$

die *Adjazenzmatrix* ( $AM$ ) des Graphen  $G$ .

# Adjazenzmatrix

## Definition 2

Sei  $G = (V, E)$  ein gerichteter Graph auf  $n$  Ecken und sei  $V := \{v_1, \dots, v_n\}$  eine Aufzählung der Ecken. Dann heißt  $A \in \mathbb{R}^{n \times n}$  mit

$$a_{ij} = \begin{cases} 1 & , \text{ falls } (v_i, v_j) \in E \\ 0 & , \text{ sonst} \end{cases}$$

die *Adjazenzmatrix* ( $AM$ ) des Graphen  $G$ .

- Gilt  $a_{ij} = 1$ , so existiert eine Kante von Ecke  $i$  zu Ecke  $j$  im zugehörigen Graphen.

# Adjazenzmatrix

## Definition 2

Sei  $G = (V, E)$  ein gerichteter Graph auf  $n$  Ecken und sei  $V := \{v_1, \dots, v_n\}$  eine Aufzählung der Ecken. Dann heißt  $A \in \mathbb{R}^{n \times n}$  mit

$$a_{ij} = \begin{cases} 1 & , \text{ falls } (v_i, v_j) \in E \\ 0 & , \text{ sonst} \end{cases}$$

die *Adjazenzmatrix* (AM) des Graphen  $G$ .

- Gilt  $a_{ij} = 1$ , so existiert eine Kante von Ecke  $i$  zu Ecke  $j$  im zugehörigen Graphen.
- Jeder Graph kann eindeutig mit seiner AM identifiziert werden und umgekehrt.

# Kennzahlen für Graphen

## Definition 3

Sei  $G = (V, E)$  ein gerichteter Graph auf  $n$  Ecken. Dann heißt

- a)  $\rho(G) := \frac{|E|}{n(n-1)}$  die Dichte des Graphen  $G$ .

# Kennzahlen für Graphen

## Definition 3

Sei  $G = (V, E)$  ein gerichteter Graph auf  $n$  Ecken. Dann heißt

a)  $\rho(G) := \frac{|E|}{n(n-1)}$  die Dichte des Graphen  $G$ .

Für  $v \in V$  heißt

# Kennzahlen für Graphen

## Definition 3

Sei  $G = (V, E)$  ein gerichteter Graph auf  $n$  Ecken. Dann heißt

a)  $\rho(G) := \frac{|E|}{n(n-1)}$  die Dichte des Graphen  $G$ .

Für  $v \in V$  heißt

b)  $\deg^{in}(v) := |\{(v_1, v_2) \in E : v_2 = v\}|$  der *In-Degree* von  $v$ .

c)  $\deg^{out}(v) := |\{(v_1, v_2) \in E : v_1 = v\}|$  der *Out-Degree* von  $v$ .



# Kennzahlen für Graphen

## Definition 3

Sei  $G = (V, E)$  ein gerichteter Graph auf  $n$  Ecken. Dann heißt

a)  $\rho(G) := \frac{|E|}{n(n-1)}$  die Dichte des Graphen  $G$ .

Für  $v \in V$  heißt

b)  $\deg^{in}(v) := |\{(v_1, v_2) \in E : v_2 = v\}|$  der *In-Degree* von  $v$ .

c)  $\deg^{out}(v) := |\{(v_1, v_2) \in E : v_1 = v\}|$  der *Out-Degree* von  $v$ .

- Der Out-Degree einer Ecke  $v$  entspricht gerade der Anzahl der von  $v$  weggehenden Kanten.
- Der In-Degree zählt entsprechend die in  $v$  eingehenden Kanten.

# Beispiel für einen Graphen


Sei  $G = (V, E)$  mit

- $V = \{A, B, C, D\}$
- $E = \{(A, B), (A, D), (C, A), (D, B)\}$

# Beispiel für einen Graphen

Sei  $G = (V, E)$  mit


- $V = \{A, B, C, D\}$
- $E = \{(A, B), (A, D), (C, A), (D, B)\}$



# Beispiel für einen Graphen

Sei  $G = (V, E)$  mit

- $V = \{A, B, C, D\}$
- $E = \{(A, B), (A, D), (C, A), (D, B)\}$




- Adjazenzmatrix  $AM = \begin{pmatrix} 0 & 1 & 0 & 1 \\ 0 & 0 & 0 & 0 \\ 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \end{pmatrix}$

# Beispiel für einen Graphen

Sei  $G = (V, E)$  mit

- $V = \{A, B, C, D\}$
- $E = \{(A, B), (A, D), (C, A), (D, B)\}$




- Adjazenzmatrix  $AM = \begin{pmatrix} 0 & 1 & 0 & 1 \\ 0 & 0 & 0 & 0 \\ 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \end{pmatrix}$
- $\rho(G) := \frac{4}{12}$

# Beispiel für einen Graphen

Sei  $G = (V, E)$  mit

- $V = \{A, B, C, D\}$
- $E = \{(A, B), (A, D), (C, A), (D, B)\}$




- Adjazenzmatrix  $AM = \begin{pmatrix} 0 & 1 & 0 & 1 \\ 0 & 0 & 0 & 0 \\ 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \end{pmatrix}$
- $\rho(G) := \frac{4}{12}$        $\deg^{out}(A) = 2$

# Beispiel für einen Graphen

Sei  $G = (V, E)$  mit

- $V = \{A, B, C, D\}$
- $E = \{(A, B), (A, D), (C, A), (D, B)\}$



- Adjazenzmatrix  $AM = \begin{pmatrix} 0 & 1 & 0 & 1 \\ 0 & 0 & 0 & 0 \\ 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \end{pmatrix}$

- $\rho(G) := \frac{4}{12}$        $\deg^{out}(A) = 2$        $\deg^{in}(A) = 1$

# Das Waffenhandelsnetzwerk als Graph

Für jedes Jahr  $x \in \{1950, \dots, 2012\}$  kann  $\text{EXP}(x)$  durch *Binarisierung* in eine Adjazenzmatrix  $A(x)$  umgewandelt werden:



# Das Waffenhandelsnetzwerk als Graph

Für jedes Jahr  $x \in \{1950, \dots, 2012\}$  kann  $\text{EXP}(x)$  durch *Binarisierung* in eine Adjazenzmatrix  $A(x)$  umgewandelt werden:

- $V := \{\text{Afghanistan}, \dots, \text{Zimbabwe}\}$  ,  $|V| = 218$

# Das Waffenhandelsnetzwerk als Graph

Für jedes Jahr  $x \in \{1950, \dots, 2012\}$  kann  $\text{EXP}(x)$  durch *Binarisierung* in eine Adjazenzmatrix  $A(x)$  umgewandelt werden:

- $V := \{\text{Afghanistan}, \dots, \text{Zimbabwe}\}$  ,  $|V| = 218$
- $a_{ij}(x) = \begin{cases} 1 & , \text{ falls } (\text{EXP}(x))_{ij} > 0 \\ 0 & , \text{ sonst} \end{cases}$

# Das Waffenhandelsnetzwerk als Graph

Für jedes Jahr  $x \in \{1950, \dots, 2012\}$  kann  $\text{EXP}(x)$  durch *Binarisierung* in eine Adjazenzmatrix  $A(x)$  umgewandelt werden:

- $V := \{\text{Afghanistan}, \dots, \text{Zimbabwe}\}$  ,  $|V| = 218$

- $$a_{ij}(x) = \begin{cases} 1 & , \text{ falls } (\text{EXP}(x))_{ij} > 0 \\ 0 & , \text{ sonst} \end{cases}$$

⇒ Für jedes Jahr erhält man einen gerichteten Graphen.

# Das Waffenhandelsnetzwerk als Graph

Für jedes Jahr  $x \in \{1950, \dots, 2012\}$  kann  $\text{EXP}(x)$  durch *Binarisierung* in eine Adjazenzmatrix  $A(x)$  umgewandelt werden:


- $V := \{\text{Afghanistan}, \dots, \text{Zimbabwe}\}$  ,  $|V| = 218$

- $$a_{ij}(x) = \begin{cases} 1 & , \text{ falls } (\text{EXP}(x))_{ij} > 0 \\ 0 & , \text{ sonst} \end{cases}$$

$\Rightarrow$  Für jedes Jahr erhält man einen gerichteten Graphen.

$\Rightarrow a_{ij}(x) = 1$  bedeutet, dass Land  $i$  im Jahr  $x$  Waffen an Land  $j$  geliefert hat.

# Reduziertes Waffenhandelsnetzwerk 1950



# Deskriptive Analyse

# Top-Exporteure

Die Top 10 der Exporteure in den Perioden 1950-1991 und 1992-2012 (vor und nach Zusammenbruch der UDSSR):

	Land	TIV
1	Soviet Union	461049.00
2	United States	438986.00
3	United Kingdom	107774.00
4	France	77960.00
5	Germany	40396.00
6	China	30659.00
7	Czechoslovakia	29113.00
8	Italy	19494.00
9	Switzerland	10613.00
10	Netherlands	10375.00

	Land	TIV
1	United States	184288.00
2	Russia	100475.00
3	Germany	36490.00
4	France	34777.00
5	United Kingdom	25353.00
6	China	15856.00
7	Netherlands	10481.00
8	Italy	9265.00
9	Ukraine	9020.00
10	Israel	8191.00

# Top-Exporteure

Die Top 10 der Exporteure in den Perioden 1950-1991 und 1992-2012 (vor und nach Zusammenbruch der UDSSR):

	Land	TIV
1	Soviet Union	461049.00
2	United States	438986.00
3	United Kingdom	107774.00
4	France	77960.00
5	Germany	40396.00
6	China	30659.00
7	Czechoslovakia	29113.00
8	Italy	19494.00
9	Switzerland	10613.00
10	Netherlands	10375.00

	Land	TIV
1	United States	184288.00
2	Russia	100475.00
3	Germany	36490.00
4	France	34777.00
5	United Kingdom	25353.00
6	China	15856.00
7	Netherlands	10481.00
8	Italy	9265.00
9	Ukraine	9020.00
10	Israel	8191.00

- Der Gesamt-Export TIV der Top 10 entspricht
  - 97,8 % des Gesamt-Export TIVs aller Nationen in der ersten Periode
  - 85,8 % des Gesamt-Export TIVs aller Nationen in der zweiten Periode



# Top-Importeure

Die Top 10 der Importeure in den Perioden 1950-1991 und 1992-2012:

	Land	TIV
1	India	66674.00
2	Germany	53652.00
3	Japan	46835.00
4	Iraq	45643.00
5	Egypt	42519.00
6	Iran	40658.00
7	Poland	38108.00
8	China	37098.00
9	Syria	36736.00
10	German D.R.	31982.00

	Land	TIV
1	India	37377.00
2	China	36732.00
3	Korea, South	25719.00
4	Turkey	22368.00
5	Saudi Arabia	20262.00
6	Taiwan	19424.00
7	Greece	17909.00
8	UAE	16088.00
9	Pakistan	15763.00
10	Egypt	15753.00





# Top-Importeure

Die Top 10 der Importeure in den Perioden 1950-1991 und 1992-2012:

	Land	TIV		Land	TIV
1	India	66674.00	1	India	37377.00
2	Germany	53652.00	2	China	36732.00
3	Japan	46835.00	3	Korea, South	25719.00
4	Iraq	45643.00	4	Turkey	22368.00
5	Egypt	42519.00	5	Saudi Arabia	20262.00
6	Iran	40658.00	6	Taiwan	19424.00
7	Poland	38108.00	7	Greece	17909.00
8	China	37098.00	8	UAE	16088.00
9	Syria	36736.00	9	Pakistan	15763.00
10	German D.R.	31982.00	10	Egypt	15753.00

- Der Gesamt-Import TIV der Top 10 entspricht
  - 35,7 % des Gesamt-Import TIVs aller Nationen in der ersten Periode
  - 45,0 % des Gesamt-Import TIVs aller Nationen in der zweiten Periode

# Barplot der Top-Akteure nach TIV



# Das Handelsnetzwerk

# Das Handelsnetzwerk

**Problem:** Die Matrizen  $EXP(x)$  bzw.  $A(x)$  enthalten für alle Jahre Nationen, welche zu diesem Zeitpunkt entweder

- noch nicht oder
- nicht mehr

existiert haben. Diese Länder verzerren das entsprechende Netzwerk.

# Das Handelsnetzwerk

**Problem:** Die Matrizen  $\text{EXP}(x)$  bzw.  $A(x)$  enthalten für alle Jahre Nationen, welche zu diesem Zeitpunkt entweder

- noch nicht oder
- nicht mehr

existiert haben. Diese Länder verzerren das entsprechende Netzwerk.

**Lösungsvorschlag:** Verwende in jedem Jahr das *Handelsnetzwerk*  $\text{EXP}^*(x)$  bzw.  $A^*(x)$ , d.h. das Netzwerk aller in diesem Jahr am Waffenhandel beteiligten Nationen.

# Das Handelsnetzwerk

**Problem:** Die Matrizen  $\text{EXP}(x)$  bzw.  $A(x)$  enthalten für alle Jahre Nationen, welche zu diesem Zeitpunkt entweder

- noch nicht oder
- nicht mehr


existiert haben. Diese Länder verzerren das entsprechende Netzwerk.

**Lösungsvorschlag:** Verwende in jedem Jahr das *Handelsnetzwerk*  $\text{EXP}^*(x)$  bzw.  $A^*(x)$ , d.h. das Netzwerk aller in diesem Jahr am Waffenhandel beteiligten Nationen.


**Vorsicht:** Für zwei Jahre  $x \neq y$  besitzen  $A^*(x)$  und  $A^*(y)$  i.A. unterschiedlich viele Knoten. Das ist bei der Interpretation zu beachten.

# Beteiligte Nationen und Dichte des Handelsnetzwerks

Anzahl der am Waffenhandel beteiligten Nationen 1950-2012





Entwicklung der Dichte des Handelsnetzwerkes 1950-2012





# Das Handelsnetzwerk 1950 und 2011

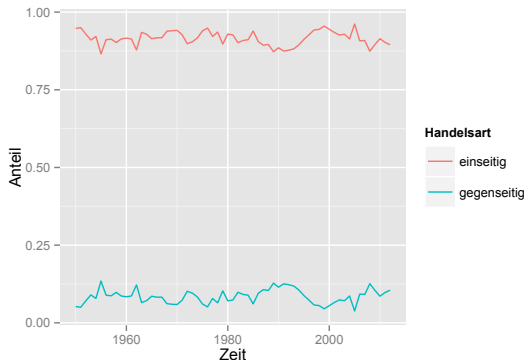


# Charakterisitische Strukturen des Handelsnetzwerks I

Ist der Handel von Waffen eher einseitig (d.h.  $a_{ij}(x) \neq a_{ji}(x)$ ) oder gegenseitig (d.h.  $a_{ij}(x) = a_{ji}(x)$ )?


# Charakterisitische Strukturen des Handelsnetzwerks I

Ist der Handel von Waffen eher einseitig (d.h.  $a_{ij}(x) \neq a_{ji}(x)$ ) oder gegenseitig (d.h.  $a_{ij}(x) = a_{ji}(x)$ )?



# Charakterisitische Strukturen des Handelsnetzwerks I

Ist der Handel von Waffen eher einseitig (d.h.  $a_{ij}(x) \neq a_{ji}(x)$ ) oder gegenseitig (d.h.  $a_{ij}(x) = a_{ji}(x)$ )?





⇒ Der Großteil der Kanten verläuft nur in eine Richtung, d.h. die Mehrzahl importiert keine Waffen von Nationen, welche sie selbst mit Waffen beliefert.

## Charakterisitische Strukturen des Handelsnetzwerks II

Wie ist die Verteilung der Anzahl der Handelspartner über die Zeit?



# Charakterisitische Strukturen des Handelsnetzwerks II

Wie ist die Verteilung der Anzahl der Handelspartner über die Zeit?



# Charakteristische Strukturen des Handelsnetzwerks II



Wie ist die Verteilung der Anzahl der Handelspartner über die Zeit?



⇒ In jedem Jahr gibt es

# Charakterisitische Strukturen des Handelsnetzwerks II

Wie ist die Verteilung der Anzahl der Handelspartner über die Zeit?





⇒ In jedem Jahr gibt es

- einen großen Anteil von Knoten mit In-Degree=1 bzw. Outdegree=0



# Charakteristische Strukturen des Handelsnetzwerks II



Wie ist die Verteilung der Anzahl der Handelspartner über die Zeit?




⇒ In jedem Jahr gibt es

- einen großen Anteil von Knoten mit In-Degree=1 bzw. Outdegree=0
- einige wenige zentrale Akteure mit sehr hohem In- bzw. Out-Degree

# Charakterisitische Strukturen des Handelsnetzwerks III



# Charakterisitische Strukturen des Handelsnetzwerks IV



# Das Exponential Random Graph Model (ERGM)

## Das Modell

**Idee:** Fasse die AM des beobachteten Netzwerks  $A^{obs}$  als Ausprägung einer matrixwertigen Zufallsvariable  $Y$  auf.

# Das Modell

**Idee:** Fasse die AM des beobachteten Netzwerks  $A^{obs}$  als Ausprägung einer matrixwertigen Zufallsvariable  $Y$  auf.

## Definition 4 (ERGM)

$$\mathbb{P}_{\theta}(Y = A) = \frac{\exp(\theta^T \cdot \Gamma(A))}{\sum_{A^* \in \mathcal{A}(N)} \exp(\theta^T \cdot \Gamma(A^*))}$$

Hierbei bezeichnet

# Das Modell

**Idee:** Fasse die AM des beobachteten Netzwerks  $A^{obs}$  als Ausprägung einer matrixwertigen Zufallsvariable  $Y$  auf.

## Definition 4 (ERGM)

$$\mathbb{P}_{\theta}(Y = A) = \frac{\exp(\theta^T \cdot \Gamma(A))}{\sum_{A^* \in \mathcal{A}(N)} \exp(\theta^T \cdot \Gamma(A^*))}$$

Hierbei bezeichnet

- $\mathcal{A}(N) := \{A \in \mathbb{R}^{(N \times N)} : a_{ij} \in \{0, 1\}, a_{ii} = 0\}$

# Das Modell

**Idee:** Fasse die AM des beobachteten Netzwerks  $A^{obs}$  als Ausprägung einer matrixwertigen Zufallsvariable  $Y$  auf.

## Definition 4 (ERGM)

$$\mathbb{P}_{\theta}(Y = A) = \frac{\exp(\theta^T \cdot \Gamma(A))}{\sum_{A^* \in \mathcal{A}(N)} \exp(\theta^T \cdot \Gamma(A^*))}$$

Hierbei bezeichnet

- $\mathcal{A}(N) := \{A \in \mathbb{R}^{(N \times N)} : a_{ij} \in \{0, 1\}, a_{ii} = 0\}$
- $\theta \in \mathbb{R}^q$  einen Parametervektor



# Das Modell

**Idee:** Fasse die AM des beobachteten Netzwerks  $A^{obs}$  als Ausprägung einer matrixwertigen Zufallsvariable  $Y$  auf.

## Definition 4 (ERGM)

$$\mathbb{P}_{\theta}(Y = A) = \frac{\exp(\theta^T \cdot \Gamma(A))}{\sum_{A^* \in \mathcal{A}(N)} \exp(\theta^T \cdot \Gamma(A^*))}$$

Hierbei bezeichnet

- $\mathcal{A}(N) := \{A \in \mathbb{R}^{(N \times N)} : a_{ij} \in \{0, 1\}, a_{ii} = 0\}$
- $\theta \in \mathbb{R}^q$  einen Parametervektor
- $\Gamma : \mathcal{A}(N) \rightarrow \mathbb{R}^q, A \mapsto (\Gamma_1(A), \dots, \Gamma_q(A))^T$  Netzwerkstatistikenvektor

# Das Modell

**Idee:** Fasse die AM des beobachteten Netzwerks  $A^{obs}$  als Ausprägung einer matrixwertigen Zufallsvariable  $Y$  auf.

## Definition 4 (ERGM)

$$\mathbb{P}_\theta(Y = A) = \frac{\exp(\theta^T \cdot \Gamma(A))}{\sum_{A^* \in \mathcal{A}(N)} \exp(\theta^T \cdot \Gamma(A^*))}$$

Hierbei bezeichnet

- $\mathcal{A}(N) := \{A \in \mathbb{R}^{(N \times N)} : a_{ij} \in \{0, 1\}, a_{ii} = 0\}$
- $\theta \in \mathbb{R}^q$  einen Parametervektor
- $\Gamma : \mathcal{A}(N) \rightarrow \mathbb{R}^q, A \mapsto (\Gamma_1(A), \dots, \Gamma_q(A))^T$  Netzwerkstatistikenvektor
- $c(\theta) := \sum_{A^* \in \mathcal{A}(N)} \exp(\theta^T \cdot \Gamma(A^*))$  eine Normierungskonstante

## Bemerkungen und Notationen

- Über  $\Gamma(\cdot)$  können die am Netzwerk beobachteten Strukturen mit in die Modellierung aufgenommen werden (z.B. einseitiger Handel, hohe Anzahl von In-Degree=1 Knoten,...).

## Bemerkungen und Notationen

- Über  $\Gamma(\cdot)$  können die am Netzwerk beobachteten Strukturen mit in die Modellierung aufgenommen werden (z.B. einseitiger Handel, hohe Anzahl von In-Degree=1 Knoten,...).
- Die Wahl von  $\Gamma(\cdot)$  beeinflusst das resultierende Modell also maßgeblich.

## Bemerkungen und Notationen

- Über  $\Gamma(\cdot)$  können die am Netzwerk beobachteten Strukturen mit in die Modellierung aufgenommen werden (z.B. einseitiger Handel, hohe Anzahl von In-Degree=1 Knoten,...).
- Die Wahl von  $\Gamma(\cdot)$  beeinflusst das resultierende Modell also maßgeblich.
- Für ein Netzwerk  $A$  gilt:

# Bemerkungen und Notationen

- Über  $\Gamma(\cdot)$  können die am Netzwerk beobachteten Strukturen mit in die Modellierung aufgenommen werden (z.B. einseitiger Handel, hohe Anzahl von In-Degree=1 Knoten,...).
- Die Wahl von  $\Gamma(\cdot)$  beeinflusst das resultierende Modell also maßgeblich.
- Für ein Netzwerk  $A$  gilt:
  - $A_{ij}^+$  bzw.  $A_{ij}^-$  entsteht aus  $A$ , indem man  $a_{ij} = 1$  bzw.  $a_{ij} = 0$  setzt.

# Bemerkungen und Notationen

- Über  $\Gamma(\cdot)$  können die am Netzwerk beobachteten Strukturen mit in die Modellierung aufgenommen werden (z.B. einseitiger Handel, hohe Anzahl von In-Degree=1 Knoten,...).
- Die Wahl von  $\Gamma(\cdot)$  beeinflusst das resultierende Modell also maßgeblich.
- Für ein Netzwerk  $A$  gilt:
  - $A_{ij}^+$  bzw.  $A_{ij}^-$  entsteht aus  $A$ , indem man  $a_{ij} = 1$  bzw.  $a_{ij} = 0$  setzt.
  - $A_{ij}^c$  bezeichnet das Netzwerk  $A$  ohne  $a_{ij}$ , d.h. das *Restnetzwerk*.

# Bemerkungen und Notationen

- Über  $\Gamma(\cdot)$  können die am Netzwerk beobachteten Strukturen mit in die Modellierung aufgenommen werden (z.B. einseitiger Handel, hohe Anzahl von In-Degree=1 Knoten,...).
- Die Wahl von  $\Gamma(\cdot)$  beeinflusst das resultierende Modell also maßgeblich.
- Für ein Netzwerk  $A$  gilt:
  - $A_{ij}^+$  bzw.  $A_{ij}^-$  entsteht aus  $A$ , indem man  $a_{ij} = 1$  bzw.  $a_{ij} = 0$  setzt.
  - $A_{ij}^c$  bezeichnet das Netzwerk  $A$  ohne  $a_{ij}$ , d.h. das *Restnetzwerk*.
  - Den Ausdruck  $(\Delta A)_{ij} := \Gamma(A_{ij}^+) - \Gamma(A_{ij}^-)$  bezeichnet man als *Change-Statistik*.



## Interpretation der Modellparameter: Kantenebene

Es gilt der Zusammenhang:

$$\frac{\mathbb{P}_{\theta}(Y_{ij} = 1 | Y_{ij}^c = A_{ij}^c)}{\mathbb{P}_{\theta}(Y_{ij} = 0 | Y_{ij}^c = A_{ij}^c)} = \exp(\theta_1(\Delta_1 A)_{ij}) \cdot \dots \cdot \exp(\theta_q(\Delta_q A)_{ij})$$

# Interpretation der Modellparameter: Kantenebene

Es gilt der Zusammenhang:

$$\frac{\mathbb{P}_{\theta}(Y_{ij} = 1 | Y_{ij}^c = A_{ij}^c)}{\mathbb{P}_{\theta}(Y_{ij} = 0 | Y_{ij}^c = A_{ij}^c)} = \exp(\theta_1(\Delta_1 A)_{ij}) \cdot \dots \cdot \exp(\theta_q(\Delta_q A)_{ij})$$

*Ceteris-Paribus-Analyse:* Vergrößert sich *nur* die  $k$ -te Change-Statistik um eine Einheit, so wird die bedingte Chance der Entstehung der Kante  $ij$  mit dem Faktor  $\exp(\theta_k)$  multipliziert.

# Interpretation der Modellparameter: Kantenebene

Es gilt der Zusammenhang:

$$\frac{\mathbb{P}_{\theta}(Y_{ij} = 1 | Y_{ij}^c = A_{ij}^c)}{\mathbb{P}_{\theta}(Y_{ij} = 0 | Y_{ij}^c = A_{ij}^c)} = \exp(\theta_1(\Delta_1 A)_{ij}) \cdot \dots \cdot \exp(\theta_q(\Delta_q A)_{ij})$$

*Ceteris-Paribus-Analyse:* Vergrößert sich *nur* die  $k$ -te Change-Statistik um eine Einheit, so wird die bedingte Chance der Entstehung der Kante  $ij$  mit dem Faktor  $\exp(\theta_k)$  multipliziert.

Dies führt zu folgender Interpretation des Parameters  $\theta_k$ ,  $k \in \{1, \dots, q\}$ :

- Ist  $\theta_k > 0$ , so steigt die bedingte Chance der Dyadenentstehung.
- Ist  $\theta_k = 0$ , so bleibt die bedingte Chance unverändert.
- Ist  $\theta_k < 0$ , so sinkt die bedingte Chance.

## Interpretation der Modellparameter: Netzwerkebene

Für eine Adjazenzmatrix  $A$  sei  $A^{k-}$  ein Netzwerk mit

$$\Gamma_I(A^{k-}) = \begin{cases} \Gamma_I(A) & \text{falls } I \in \{1, \dots, q\} \setminus \{k\} \\ \Gamma_I(A) - 1 & \text{falls } I = k \end{cases}$$

# Interpretation der Modellparameter: Netzwerkebene

Für eine Adjazenzmatrix  $A$  sei  $A^{k-}$  ein Netzwerk mit

$$\Gamma_I(A^{k-}) = \begin{cases} \Gamma_I(A) & \text{falls } I \in \{1, \dots, q\} \setminus \{k\} \\ \Gamma_I(A) - 1 & \text{falls } I = k \end{cases}$$

Dann gilt der Zusammenhang

$$\frac{\mathbb{P}_\theta(Y = A)}{\mathbb{P}_\theta(Y = A^{k-})} = \exp(\theta_k)$$

# Interpretation der Modellparameter: Netzwerkebene

Für eine Adjazenzmatrix  $A$  sei  $A^{k-}$  ein Netzwerk mit

$$\Gamma_I(A^{k-}) = \begin{cases} \Gamma_I(A) & \text{falls } I \in \{1, \dots, q\} \setminus \{k\} \\ \Gamma_I(A) - 1 & \text{falls } I = k \end{cases}$$

Dann gilt der Zusammenhang

$$\frac{\mathbb{P}_\theta(Y = A)}{\mathbb{P}_\theta(Y = A^{k-})} = \exp(\theta_k)$$

⇒ Die relative Plausibilität, dass das Netzwerk  $A$  im Vergleich zu Netzwerk  $A^{k-}$  entsteht beträgt gerade  $\exp(\theta_k)$ .

# Interpretation der Modellparameter: Netzwerkebene

Für eine Adjazenzmatrix  $A$  sei  $A^{k-}$  ein Netzwerk mit

$$\Gamma_I(A^{k-}) = \begin{cases} \Gamma_I(A) & \text{falls } I \in \{1, \dots, q\} \setminus \{k\} \\ \Gamma_I(A) - 1 & \text{falls } I = k \end{cases}$$

Dann gilt der Zusammenhang

$$\frac{\mathbb{P}_\theta(Y = A)}{\mathbb{P}_\theta(Y = A^{k-})} = \exp(\theta_k)$$

⇒ Die relative Plausibilität, dass das Netzwerk  $A$  im Vergleich zu Netzwerk  $A^{k-}$  entsteht beträgt gerade  $\exp(\theta_k)$ .

- Ist  $\theta_k > 0$ , so ist  $A$  plausibler als  $A^{k-}$ .
- Ist  $\theta_k = 0$ , so sind sie gleich plausibel.
- Ist  $\theta_k < 0$ , so ist  $A^{k-}$  plausibler als  $A$ .

# Schätzung der Modellparameter I

Sei  $A^{obs} \in \mathcal{A}(N)$  das beobachtete Netzwerk.



# Schätzung der Modellparameter I

Sei  $A^{obs} \in \mathcal{A}(N)$  das beobachtete Netzwerk.

⇒ Log-Likelihood

$$\text{loglik}(\theta) = \theta^T \cdot \Gamma(A^{obs}) - \log(c(\theta))$$

# Schätzung der Modellparameter I

Sei  $A^{obs} \in \mathcal{A}(N)$  das beobachtete Netzwerk.

⇒ Log-Likelihood

$$\text{loglik}(\theta) = \theta^T \cdot \Gamma(A^{obs}) - \log(c(\theta))$$

**Problem:** Schon für relativ kleines  $N$  lässt sich

$$c(\theta) = \sum_{A^* \in \mathcal{A}(N)} \exp(\theta^T \cdot \Gamma(A^*))$$

nicht mehr (in absehbarer Zeit) berechnen!

# Schätzung der Modellparameter I

Sei  $A^{obs} \in \mathcal{A}(N)$  das beobachtete Netzwerk.

$\Rightarrow$  Log-Likelihood

$$\text{loglik}(\theta) = \theta^T \cdot \Gamma(A^{obs}) - \log(c(\theta))$$

**Problem:** Schon für relativ kleines  $N$  lässt sich

$$c(\theta) = \sum_{A^* \in \mathcal{A}(N)} \exp(\theta^T \cdot \Gamma(A^*))$$

nicht mehr (in absehbarer Zeit) berechnen!

**Grund:** Beispielsweise enthält schon für ein Netzwerk mit 100 Knoten die Menge  $\mathcal{A}(100)$  genau  $2^{9900}$  Elemente.

## Schätzung der Modellparameter II

**Idee:** Fixiere  $\theta_0 \in \mathbb{R}^q$ . Dann gilt der Zusammenhang

$$\frac{c(\theta)}{c(\theta_0)} = \mathbb{E}_{\theta_0} \left[ \exp \left( (\theta - \theta_0)^T \cdot \Gamma(Y) \right) \right]$$

## Schätzung der Modellparameter II

**Idee:** Fixiere  $\theta_0 \in \mathbb{R}^q$ . Dann gilt der Zusammenhang

$$\frac{c(\theta)}{c(\theta_0)} = \mathbb{E}_{\theta_0} \left[ \exp \left( (\theta - \theta_0)^T \cdot \Gamma(Y) \right) \right]$$

Simuliere nun via MCMC (z.B. *Metropolis-Hastings*) eine *große* Anzahl von Zufallsnetzwerken  $A_1, \dots, A_L$  aus der Verteilung von  $\mathbb{P}_{\theta_0}$ .

## Schätzung der Modellparameter II

**Idee:** Fixiere  $\theta_0 \in \mathbb{R}^q$ . Dann gilt der Zusammenhang

$$\frac{c(\theta)}{c(\theta_0)} = \mathbb{E}_{\theta_0} \left[ \exp \left( (\theta - \theta_0)^T \cdot \Gamma(Y) \right) \right]$$

Simuliere nun via MCMC (z.B. *Metropolis-Hastings*) eine *große* Anzahl von Zufallsnetzwerken  $A_1, \dots, A_L$  aus der Verteilung von  $\mathbb{P}_{\theta_0}$ .

Nach dem *Gesetz der großen Zahlen* gilt dann

$$\frac{c(\theta)}{c(\theta_0)} \approx \frac{1}{L} \cdot \sum_{i=1}^L \exp \left( (\theta - \theta_0)^T \cdot \Gamma(A_i) \right)$$

## Schätzung der Modellparameter II

**Idee:** Fixiere  $\theta_0 \in \mathbb{R}^q$ . Dann gilt der Zusammenhang

$$\frac{c(\theta)}{c(\theta_0)} = \mathbb{E}_{\theta_0} \left[ \exp \left( (\theta - \theta_0)^T \cdot \Gamma(Y) \right) \right]$$

Simuliere nun via MCMC (z.B. *Metropolis-Hastings*) eine *große* Anzahl von Zufallsnetzwerken  $A_1, \dots, A_L$  aus der Verteilung von  $\mathbb{P}_{\theta_0}$ .

Nach dem *Gesetz der großen Zahlen* gilt dann

$$\frac{c(\theta)}{c(\theta_0)} \approx \frac{1}{L} \cdot \sum_{i=1}^L \exp \left( (\theta - \theta_0)^T \cdot \Gamma(A_i) \right)$$

und damit

$$\text{loglik}(\theta) - \text{loglik}(\theta_0) \approx -\log \left( \frac{1}{L} \cdot \sum_{i=1}^L \exp \left( (\theta - \theta_0)^T \cdot \Gamma(A_i) \right) \right)$$

# Inferentielle Analyse



# Netzwerkstatistiken I

**Ziel:** Formuliere die gefundenen Strukturen als Netzwerkstatistiken  $\Gamma_k(\cdot)$ .

# Netzwerkstatistiken I

**Ziel:** Formuliere die gefundenen Strukturen als Netzwerkstatistiken  $\Gamma_k(\cdot)$ .

- Einseitiger Handel:

$$\Gamma_{asym} : \mathcal{A}(N) \rightarrow \mathbb{R} \quad , \quad A \mapsto \# \text{ einseitiger Kanten}$$

# Netzwerkstatistiken I

**Ziel:** Formuliere die gefundenen Strukturen als Netzwerkstatistiken  $\Gamma_k(\cdot)$ .

- Einseitiger Handel:

$$\Gamma_{asym} : \mathcal{A}(N) \rightarrow \mathbb{R} \quad , \quad A \mapsto \# \text{ einseitiger Kanten}$$

- In-Degree=1:

$$\Gamma_{deg1} : \mathcal{A}(N) \rightarrow \mathbb{R} \quad , \quad A \mapsto \# \text{ In-Degree=1 Knoten}$$

# Netzwerkstatistiken I

**Ziel:** Formuliere die gefundenen Strukturen als Netzwerkstatistiken  $\Gamma_k(\cdot)$ .

- Einseitiger Handel:

$$\Gamma_{asym} : \mathcal{A}(N) \rightarrow \mathbb{R} \quad , \quad A \mapsto \# \text{ einseitiger Kanten}$$

- In-Degree=1:

$$\Gamma_{ideg1} : \mathcal{A}(N) \rightarrow \mathbb{R} \quad , \quad A \mapsto \# \text{ In-Degree=1 Knoten}$$

- Anzahl Kanten:

$$\Gamma_{edges} : \mathcal{A}(N) \rightarrow \mathbb{R} \quad , \quad A \mapsto \# \text{ Kanten}$$

## Netzwerkstatistiken II

Schließlich soll noch eine Statistik integriert werden, welche die (wenigen) Knoten mit hohem Out-Degree mit modelliert.

## Netzwerkstatistiken II


Schließlich soll noch eine Statistik integriert werden, welche die (wenigen) Knoten mit hohem Out-Degree mit modelliert. Verwende:

$$\Gamma_{dsp1}(A) := |\{(v_1, v_2) \in V^2 : \exists! v_3 \in V \text{ s.t. } (v_1, v_3) \in E \wedge (v_3, v_2) \in E\}|$$

## Netzwerkstatistiken II

Schließlich soll noch eine Statistik integriert werden, welche die (wenigen) Knoten mit hohem Out-Degree mit modelliert. Verwende:

$$\Gamma_{dsp1}(A) := |\{(v_1, v_2) \in V^2 : \exists! v_3 \in V \text{ s.t. } (v_1, v_3) \in E \wedge (v_3, v_2) \in E\}|$$



# Ein ERGM für das Handelsnetzwerk

- Sei  $N(x)$  die Anzahl der Knoten des Handelsnetzwerks im Jahr  $x$ .



# Ein ERGM für das Handelsnetzwerk

- Sei  $N(x)$  die Anzahl der Knoten des Handelsnetzwerks im Jahr  $x$ .
- Für jedes Jahr  $x \in \{1950, \dots, 2012\}$  wird das Modell





$$\mathbb{P}_{\theta}(Y = A) = \frac{\exp(\theta^T \cdot \Gamma(A))}{\sum_{A^* \in \mathcal{A}(N(x))} \exp(\theta^T \cdot \Gamma_1(A^*))}$$

mit dem Statistikenvektor


$$\Gamma(A) := (\Gamma_{edges}(A), \Gamma_{asym}(A), \Gamma_{ideg1}(A), \Gamma_{dsp1}(A))^T$$

geschätzt.


# Entwicklung der Koeffizientenschätzer über die Zeit

Entwicklung von  $\Theta_{edges}$ Entwicklung von  $\Theta_{ideg1}$ Entwicklung von  $\Theta_{asym}$ Entwicklung von  $\Theta_{dsp1}$ 

# Interpretation von $\theta_{edges}$




# Interpretation von $\theta_{edges}$




- Für alle Jahre besteht ein negativer Effekt.

# Interpretation von $\theta_{edges}$




- Für alle Jahre besteht ein negativer Effekt.
- **Kantenebene:** Hier nicht möglich, da Change-Statistik konstant 1.

# Interpretation von $\theta_{edges}$




- Für alle Jahre besteht ein negativer Effekt.
- **Kantenebene:** Hier nicht möglich, da Change-Statistik konstant 1.
- **Netzwerkebene:** Das Netzwerk  $A^{edges-}$  ist immer plausibler als das Netzwerk  $A$ .

# Interpretation von $\theta_{edges}$




- Für alle Jahre besteht ein negativer Effekt.
- **Kantenebene:** Hier nicht möglich, da Change-Statistik konstant 1.
- **Netzwerkebene:** Das Netzwerk  $A^{edges-}$  ist immer plausibler als das Netzwerk  $A$ .

# Interpretation von $\theta_{ideg1}$






# Interpretation von $\theta_{ideg1}$




- Für alle Jahre besteht ein positiver Effekt.

# Interpretation von $\theta_{ideg1}$




- Für alle Jahre besteht ein positiver Effekt.
- **Kantenebene:** Sind zwei Netzwerke  $A, B$  bekannt bis auf die Kante  $(i, j)$  und ist nur die  $ideg1$ -Change-Statistik von  $A$  um eins größer als die von  $B$ , so entsteht die Kante  $(i, j)$  eher in  $A$ .

# Interpretation von $\theta_{ideg1}$



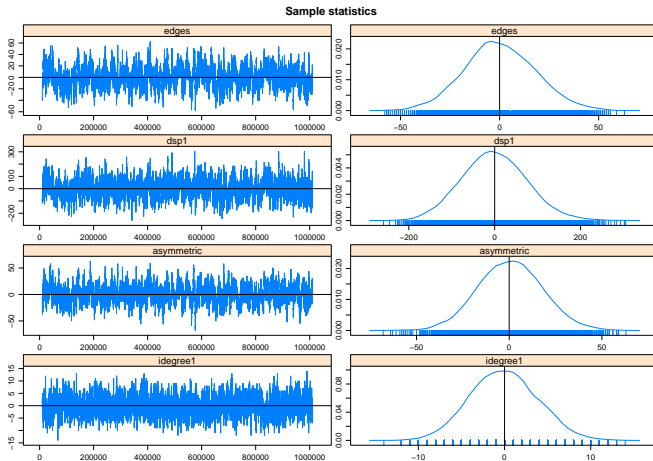
- Für alle Jahre besteht ein positiver Effekt.
- **Kantenebene:** Sind zwei Netzwerke  $A, B$  bekannt bis auf die Kante  $(i, j)$  und ist nur die  $ideg1$ -Change-Statistik von  $A$  um eins größer als die von  $B$ , so entsteht die Kante  $(i, j)$  eher in  $A$ .
- **Netzwerkebene:** Das Netzwerk  $A^{ideg1-}$  ist immer weniger plausibel als das Netzwerk  $A$ .

# Interpretation von $\theta_{ideg1}$




- Für alle Jahre besteht ein positiver Effekt.
- **Kantenebene:** Sind zwei Netzwerke  $A, B$  bekannt bis auf die Kante  $(i, j)$  und ist nur die  $ideg1$ -Change-Statistik von  $A$  um eins größer als die von  $B$ , so entsteht die Kante  $(i, j)$  eher in  $A$ .
- **Netzwerkebene:** Das Netzwerk  $A^{ideg1-}$  ist immer weniger plausibel als das Netzwerk  $A$ .

## MCMC-Diagnose für 2012




## Goodness-of-fit für 2012


Dyad-wise shared partners




Edge-wise shared partners



Geodesic distance



In-degree distribution





# Strukturgleiche Netzwerke

**Problem:** Werden nur *endogene* Statistiken in das Modell aufgenommen, so erhalten strukturgleiche Netzwerke dieselbe Wahrscheinlichkeitsmasse.

# Strukturgleiche Netzwerke

**Problem:** Werden nur *endogene* Statistiken in das Modell aufgenommen, so erhalten strukturgleiche Netzwerke dieselbe Wahrscheinlichkeitsmasse.





# Strukturgleiche Netzwerke

**Problem:** Werden nur *endogene* Statistiken in das Modell aufgenommen, so erhalten strukturgleiche Netzwerke dieselbe Wahrscheinlichkeitsmasse.



**Lösung:** Integration von *exogenen* Statistiken (d.h. Kovariablen)

## Kovariable: *Alliance Treaty Obligations and Provisions*

## Kovariable: *Alliance Treaty Obligations and Provisions*

- Daten über Verteidigungsabkommen (VA) von der *Rice University*

## Kovariable: *Alliance Treaty Obligations and Provisions*

- Daten über Verteidigungsabkommen (VA) von der *Rice University*
- Für jedes Jahr  $x \in \{1969, \dots, 2012\}$  liegt eine symmetrische Matrix  $C(x)$  vor mit

$$c_{ij}(x) = \begin{cases} 1 & , \text{ falls } i \text{ und } j \text{ haben VA} \\ 0 & , \text{ sonst} \end{cases}$$

## Kovariabel: *Alliance Treaty Obligations and Provisions*


- Daten über Verteidigungsabkommen (VA) von der *Rice University*
- Für jedes Jahr  $x \in \{1969, \dots, 2012\}$  liegt eine symmetrische Matrix  $C(x)$  vor mit


$$c_{ij}(x) = \begin{cases} 1 & , \text{ falls } i \text{ und } j \text{ haben VA} \\ 0 & , \text{ sonst} \end{cases}$$

- Diese können über die Statistik

$$\Gamma_{C(x)} : \mathcal{A}(N(x)) \rightarrow \mathbb{R} \quad , \quad A \mapsto \sum_{i=1}^{N(x)} \sum_{j=1}^{N(x)} a_{ij} c(x)_{ij}$$


in das Modell integriert werden.

Entwicklung von  $\theta_{VA}$ 

Entwicklung von  $\theta_{VA}$ 

- Stark positiver Effekt über den gesamten Zeitraum.

# Entwicklung von $\theta_{VA}$




- Stark positiver Effekt über den gesamten Zeitraum.
- **Interpretation:** Von zwei strukturgleichen Netzwerken ist dasjenige plausibler, welches mehr Übereinstimmungen mit dem Netzwerk der VA aufweist.




# Goodness-of-fit für 2012 mit Kovariable VA


**Dyad-wise shared partners**




**Edge-wise shared partners**



**Geodesic distance**




**In-degree distribution**




# GOF für 2012 mit Kovariable VA, BIP, Militärausgaben


## Dyad-wise shared partners




## Edge-wise shared partners



## Geodesic distance



## In-degree distribution



Wie könnte das Modell verbessert werden?

## Wie könnte das Modell verbessert werden?

- Einbinden weiterer Kovariablen, z.B.:

# Wie könnte das Modell verbessert werden?

- Einbinden weiterer Kovariablen, z.B.:
  - *geographische Distanz*
  - *Konfliktnetzwerke*
  - *Handelsabhängigkeiten*

# Wie könnte das Modell verbessert werden?

- Einbinden weiterer Kovariablen, z.B.:
  - *geographische Distanz*
  - *Konfliktnetzwerke*
  - *Handelsabhängigkeiten*
- Berücksichtigung der zeitlichen Struktur über *T(emporal) ERGMs*.

# Wie könnte das Modell verbessert werden?

- Einbinden weiterer Kovariablen, z.B.:
  - *geographische Distanz*
  - *Konfliktnetzwerke*
  - *Handelsabhängigkeiten*
- Berücksichtigung der zeitlichen Struktur über *T(emporal) ERGMs*.
- Berücksichtigung der Gewichtung über *G(eneralized) ERGMs*.

# Wie könnte das Modell verbessert werden?

- Einbinden weiterer Kovariablen, z.B.:
  - *geographische Distanz*
  - *Konfliktnetzwerke*
  - *Handelsabhängigkeiten*
- Berücksichtigung der zeitlichen Struktur über *T(emporal) ERGMs*.
- Berücksichtigung der Gewichtung über *G(eneralized) ERGMs*.
- Betrachtung von verkleinerten Netzwerken mit über die Zeit fixierten Knoten.



Vielen Dank für Ihre  
Aufmerksamkeit!